让检索按需发生

面向知识问答的自适应检索增强生成（RAG）

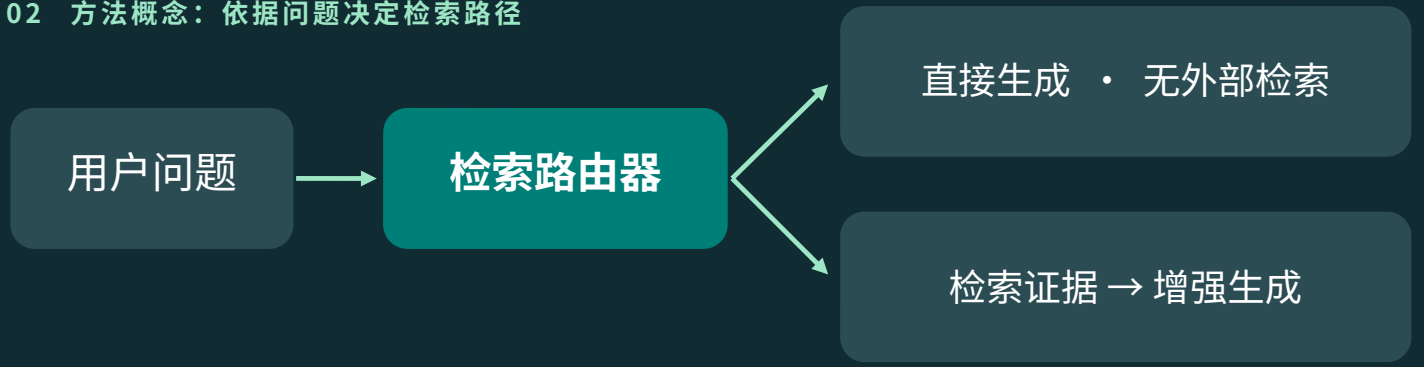
01 研究问题

每个问题都需要同样强度的检索吗？

固定检索可能带来无关证据，
也可能为简单问题增加延迟。

目标：在答案质量、证据支撑
与推理成本之间取得平衡。

02 方法概念：依据问题决定检索路径



路由信号 问题特征 + 独立开发集上校准的置信信号

归因重点 固定模型与知识库，隔离路由策略的实际收益

用公平对照验证：收益是否来自路由?

先确定质量容忍范围，再比较成本；开发集选阈值，测试集只做最终评估。

01 对照组

无检索 LLM

固定 Top-k RAG

自适应 RAG （待验证）

02 评估指标

答案质量： EM / Token F1

证据支撑：引用核验

成本： P50 / P95 延迟、 Token

03 消融与控制

随机路由：相同检索比例

固定模型、知识库与预算

阈值敏感性与多次运行

待验证假设 在预设质量容忍范围内，减少检索调用与端到端延迟。

主要风险：错误跳过检索、置信度失准、跨领域退化；需逐类统计失败案例。

背景： Lewis et al., NeurIPS 2020 （RAG）； Jeong et al., NAACL 2024 （Adaptive-RAG）。